

О проекте

Для работы был использован датасет, предоставленный учебной платформой.

Цели проекта:

1. С помощью данных о покупках клиентов и их социально-демографических признаках проанализировать эффективность проведенных маркетинговых кампаний и выявить факторы, способные повысить продажи.
2. Провести бинарную классификацию и заполнить данные о поле клиентов, утерянные при формировании базы.
3. Провести кластеризацию клиентов и предложить методы работы с каждым кластером.
4. Построить модель склонности клиентов к покупке.

Исходные данные

Для анализа были предоставлена база данных, содержащая следующие таблицы с данными:

- `personal_data` — ID клиентов, их пол, возраст, образование, страна и город проживания;
- `personal_data_coeffs` — данные с персональными коэффициентами клиентов, которые рассчитываются по некоторой закрытой схеме;
- `purchases` — данные о покупках: ID покупателя, название товара, цвет, стоимость, гендерная принадлежность потенциальных покупателей товара, наличие скидки и дата покупки.

А также дополнительная таблица `loss_data`, с данными, которые были утеряны при передаче

После объединения всех доступных данных была получена таблица вида:

id	gender	age	education	city	country	personal_coef	product	colour	cost	product_sex	base_sale	dt
0	0	0.00	36	среднее	1201	32	0.51	Велосипед горный женский Stern Mira 2.0 26"	двухцветный	13599	0.00	1 7
1	0	0.00	36	среднее	1201	32	0.51	Стол Outventure	зелёный	1499	3.00	0 37
2	0	0.00	36	среднее	1201	32	0.51	Набор Outventure: стол + 4 стула	бежевый	4799	3.00	0 37
3	3	NaN	31	среднее	1134	32	0.43	Бутсы мужские GSD Astro	белый	1599	1.00	0 13
4	3	NaN	31	среднее	1134	32	0.43	Мяч футбольный PUMA TEAMFINAL 21.2 FIFA QUALIT...	мультицвет	7199	3.00	0 27
5	3	NaN	31	среднее	1134	32	0.43	Кеды мужские FILA A-Low	белый	2799	1.00	1 34
6	3	NaN	31	среднее	1134	32	0.43	Полуботинки мужские Outventure Chase	серый	2999	1.00	0 34
7	4	0.00	35	среднее	1134	32	0.51	Роликовые коньки детские Roces Orlando III	двухцветный	9199	3.00	0 0
8	4	0.00	35	среднее	1134	32	0.51	Шлем FILA NRK FUN	белый	4999	3.00	0 0
9	4	0.00	35	среднее	1134	32	0.51	Роликовые коньки детские Roces Yuma TIF	мультицвет	6999	3.00	0 1

Таблица 1. Объединенные данные

После объединения были выявлены и обработаны следующие проблемы в данных:

- Многоцветные товары. Товары, содержащие 2 цвета были отнесены к категории “Двухцветные”, товары, содержащие более 2 цветов были отнесены к категории “Мультицвет”
- Половая принадлежность. Товары, с пропусками в колонке с половой принадлежностью были разделены на категории детских и унисекс товаров
- Редко встречающиеся цвета. Цвета, которые имели низкую частоту были отнесены к категории “Редкие”
- Некорректные данные. Были удалены записи с ценой товара меньше нуля и возрастом клиента меньше 16 лет
- Пропуски данных о гендере. Были обработаны с помощью ML модели бинарной классификации

Проделанная работа позволила добиться максимально возможной полноты данных, для проведения корректного анализа

A/B тесты. Первая рекламная кампания

Первая маркетинговая кампания проводилась в период с 5-го по 16-й день и включала в себя предоставление персональной скидки 5 000 клиентам через email-рассылку.

Было сформулировано две гипотезы:

- H0: Предоставление персональной скидки не влияет на доход с пользователя и количество покупок, которые он совершает
- H1: Предоставление персональной скидки значительно (>10%) повышает доход с пользователя или количество покупок, которые он совершает

По итогам теста были подсчитаны следующие метрики:

- Средний и медианный доход с пользователя
- Средняя и медианная цена товара среди всех покупок пользователя
- Среднее и медианное число покупок пользователя

По результатам A/B теста можно наблюдать рост среднего и медианного дохода с пользователя, и рост среднего и медианного числа покупок у тестовой группы. P-value = $1.6933073717894537e-35$ и $1.079537091106142e-81$ соответственно, что говорит о крайне низкой вероятности случайности полученных результатов

Средняя и медианная цена товара среди покупок пользователя немного упала. При этом P-value = 0.61695, что говорит о том, что, скорее всего, падение вызвано случайными колебаниями



Рисунок 1. Результаты A/B теста первой рекламной кампании

Из этого можно сделать вывод, что во время проведения первой рекламной компании пользователи стали покупать больше товаров и приносить больше прибыли.
В этом случае принимается H1

A/B тесты. Вторая рекламная кампания

Вторая кампания проводилась на жителях города 1 134 и представляла собой баннерную рекламу на билбордах: скидка всем каждое 15-е число месяца (15-й и 45-й день в нашем случае)

Было сформулировано две гипотезы:

- H0: Баннерная реклама на билбордах не стимулирует пользователей совершать покупки чаще, или покупать более дорогостоящие товары
- H1: Баннерная реклама на билбордах стимулирует повышает доход в день акции более чем на 10%

По итогам теста были подсчитаны следующие дневные показатели за весь период кампании:

- Доход
- Количество заказов
- Количество уникальных пользователей




Рисунок 2. Результаты A/B теста второй рекламной кампании

На графике можно увидеть, что с 0 по 16 день доход колеблется в промежутке между 80 и 120 млн, а после 16 дня падает до промежутка 40-70 млн

Самым прибыльным днем оказался 14. 15 акционный день при этом является вторым по уровню прибыли за все время рекламной кампании, но явно не выделяется на промежутке 0 - 16 дней

45 акционный день, в свою очередь, не выделяется на промежутке 17-58 дней

По результатам второго A/B теста можно сделать вывод, что 15 акционный день, скорее всего, случайно стал вторым по уровню прибыли, а рекламная компания незначительно повлияла на уровень дохода, количество заказов и уникальных пользователей

Также стоит отметить, что для адекватного анализа данных слишком мало: акционных дней всего 2 и нет никаких данных о промежутке с 0 по 16 день, из-за чего невозможно объяснить повышенный спрос в этот период

В этом случае принимается H_0

Кластеризация

В ходе кластеризации удалось выявить 8 основных кластеров клиентов:




Рисунок 3. Кластеризация. Кластеры сгруппированы и разделены по цвету

Кластер 0 - Самый крупный кластер. Мужчины среднего возраста, с средним образованием, с высокими расходами на покупки. В основном покупают товары категорий для мужчин и унисекс, остальными категориями интересуются мало. Скидка мало влияет на вероятность покупки. Методы работы с кластером: подойдут предложения с дорогими/премиальными товарами известных брендов, с акцентом на качество и статусность

Кластер 1 - Второй по величине кластер. Женщины среднего возраста, с средним образованием, со средними расходами на покупки. В основном покупают товары категорий для женщин и унисекс, умеренно интересуются остальными категориями. Скидка мало влияет на вероятность покупки. Методы работы с кластером: подойдут предложения среднего ценового сегмента, с акцентом на цена=качество

Кластер 2* - Третий по величине кластер. Молодые мужчины, с высшим образованием, с высокими расходами на покупки. В основном покупают товары категорий для мужчин и унисекс, остальными категориями интересуются мало. Скидка мало влияет на вероятность покупки. Методы работы с кластером: подойдут

предложения с дорогими/премиальными товарами известных брендов, с акцентом на качество и статусность

Кластер 3 - Четвертый по величине кластер. Женщины среднего возраста, с средним образованием, с низкими расходами на покупки. В основном покупают товары категорий для женщин, все остальные категории имеют умеренный спрос.

Предпочитают товары по скидке. Методы работы с кластером: подойдут предложения с товарами низкой/средней ценовой категорией, в качестве мотивации к покупке стоит использовать скидку

Кластер 4 - Пятый по величине кластер. Мужчины среднего возраста, с средним образованием, со средними расходами на покупки. В основном покупают товары категорий для мужчин, мало интересуются товарами для детей и умеренно интересуются товарами для женщин и унисекс. Предпочитают товары по скидке. Методы работы с кластером: подойдут предложения среднего ценового сегмента, с акцентом на цена=качество, в качестве мотивации к покупке стоит использовать скидку

Кластер 5 - Малочисленный кластер. Молодые женщины, с высшим образованием, с низкими расходами на покупки. В основном покупают товары категорий для женщин, мало интересуются товарами для детей и умеренно интересуются товарами для мужчин и унисекс. Предпочитают товары по скидке. Методы работы с кластером: подойдут предложения с товарами низкой/средней ценовой категорией, в качестве мотивации к покупке стоит использовать скидку

Кластер 6 - Малочисленный кластер. Молодые женщины, с высшим образованием, с средними расходами на покупки. В основном покупают товары категорий для женщин и унисекс, мало интересуются товарами для детей и умеренно интересуются товарами для мужчин. Скидка мало влияет на вероятность покупки. Методы работы с кластером: подойдут предложения среднего ценового сегмента, с акцентом на цена=качество

Кластер 7 - Малочисленный кластер. Молодые мужчины, с высшим образованием, с средними расходами на покупки. В основном покупают товары категорий для мужчин и умеренно интересуются товарами категории унисекс. Остальными категориями интересуются мало. Предпочитают товары по скидке. Методы работы с кластером: подойдут предложения среднего ценового сегмента, с акцентом на цена=качество, в качестве мотивации к покупке стоит использовать скидку

Кластер 2* имеет мало отличается от Кластера 0, различия есть в возрасте и образовании. Возможно, будет уместно объединить эти кластеры, если отличающиеся переменные не влияют на качество формирования индивидуального коммерческого предложения

Основной акцент стоит сделать на 0-3 кластерах, так как они составляют большую долю покупателей. Остальные кластеры отлично подойдут для дополнительного подробного анализа и построения гипотез, которые позволят увеличить их численность/доходность

Модель склонности клиента к покупке

На основе имеющихся данных была построена модель склонности клиента к покупке, в результате работы которой была получена таблица, содержащая id клиентов и вероятность того, что конкретный клиент совершит покупку в будущем. Для удобства таблица была отсортирована по убыванию

	id	propensity_score
2621	46035	0.93
7805	137454	0.91
4808	84936	0.91
377	6305	0.91
9629	169668	0.91
4550	80311	0.91
614	10940	0.90
8799	154927	0.90
7715	135803	0.90
3679	64882	0.90

Таблица 2. Топ 10 клиентов, которые с высокой вероятностью совершат покупку в будущем

Выводы и рекомендации

По имеющимся данным можно уверенно сказать, что первая рекламная кампания была успешной, клиенты положительно реагируют на предоставление персональной скидки и ее можно использовать в будущем, для повышения дохода

По второй рекламной кампании сложно сделать однозначные выводы. С одной стороны, в акционные дни не было значимых различий в основных метриках, с другой, из-за малого количества данных и отсутствия дополнительной информации нельзя с уверенностью сказать что кампания провалилась. В этом случае стоит как минимум продолжить наблюдение еще пару месяцев, для получения полной картины

Примечания

Исходные данные:

<https://drive.google.com/drive/folders/1wk3vMP8PnMlgzNz1Rfkbp8ZCylz5dPsk>

Jupyter Notebook с кодом:

<https://drive.google.com/file/d/17OdqXdvaUDSB9rl78PmmGVhggL0ej9ej/view?usp=sharing>

Таблица 1, исходник:

<https://drive.google.com/file/d/1fSGPhy2uG6tOq0z6f44ksuwxQXN2wP3z/view?usp=sharing>

Таблица 2, исходник:

<https://drive.google.com/file/d/1cDgcMULIXUMX-xtKxh1Mxqrv4KuF6f84/view?usp=sharing>

Рисунок 1, исходник:

https://drive.google.com/file/d/1GDc0PZASJe_-qKiy438VMuLVv6pGoJ70/view?usp=sharing

Рисунок 2, исходник:

<https://drive.google.com/file/d/1G23Kq5L78A4W9fLW6oRtvrmOYdKD8UT/view?usp=sharing>

Рисунок 3, исходник:

https://drive.google.com/file/d/1bJLxA1iVnKTPmuOXc85ady2XT_Cosyy/view?usp=sharing